


ViT (Vision Transformer) 개요

- ✓ **1. CNN의 한계**
 - 지역적 패턴 중심 학습 → 전역 문맥 학습에 약함
 - 수용 영역(Receptive Field)은 깊어질수록 커지지만, 여전히 한계 존재
 - 이미지 크기나 구조 변화 시 유연성이 낮음
- ✓ **2. Transformer의 강점**
 - Self-Attention → 전역 정보 학습 강점
 - 병렬 처리 / BERT, GPT 등 NLP에서 혁신적인 성과
- ✓ **3. ViT의 핵심 개념**
 - 이미지를 다수의 패치(patch)로 분할 → 텍스트의 단어(token)처럼 처리
 - 각 패치를 벡터로 변환 후 위치 정보를 더해 Transformer 입력
 - Self-Attention으로 패치 간 전역 관계를 직접 학습



역량	파라미터	백본 LLM
이미지 이해	ViT	- CNN의 한계를 넘어 전역 문맥 학습 - 이미지 패치를 토큰처럼 처리
이미지-텍스트 융합	CLIP	- 이미지와 텍스트를 공통 임베딩 공간에 매핑 - 이미지-텍스트 검색, 제로 샷 분류 가능
설명·대화 확장	BLIP, LLaVA	- 이미지 설명 생성(Image Captioning), VQA - LLaVA: 대화형 시각+언어 모델 (LLM과 결합)
완전 멀티모달	Qwen2.5-omni, GPT-4o	- 텍스트·이미지·오디오·영상까지 직접 처리 - 복합 모달 입력/출력을 통합적으로 처리, 실시간 추론 및 생성